ĐẠI HỌC QUỐC GIA HÀ NỘI

TRƯỜNG ĐẠI HỌC CÔNG NGHỆ

KHOA CÔNG NGHỆ THÔNG TIN

BÁO CÁO BÀI TẬP

Học phần: Phân tích mạng phương tiện xã hội trong kinh doanh (INT3035)

ĐỀ TÀI 24

XÂY DỰNG MẠNG LƯỚI NGÔI SAO ÂM NHẠC, THẦN TƯỢNG K-POP/US-UK VÀ TẬP ĐOÀN GIẢI TRÍ QUỐC TẾ TỪ DỮ LIỆU BÁO CHÍ BẰNG KỸ THUẬT XỬ LÝ NGÔN NGỮ TỰ NHIÊN

Thành viên nhóm 22	**Mã sinh viên**
Nguyễn Nhật Nam	23020557
Lưu Đạt Tuấn Nghĩa	23020559

Giảng viên: TS. Trần Mai Vũ

Nguồn dữ liệu được phân công: Báo chí (mã báo chí-8)

Hà Nội, tháng 11 năm 2026

MỤC LỤC

1. Phân công công việc trong nhóm.....3

2. Giới thiệu mạng đã xây dựng.....3

2.1. Bài toán và phạm vi.....3

2.2. Lựa chọn nút.....3

2.3. Lựa chọn cạnh (loại quan hệ).....4

2.4. Ví dụ cạnh kèm dẫn chứng.....5

3. Stack công nghệ thu thập và xử lý dữ liệu.....7

3.1. Kiến trúc pipeline.....8

4. Thu thập dữ liệu.....8

5. Các bước tiền xử lý dữ liệu.....9

5.1. Trích xuất quan hệ.....10

6. Lưu trữ trong Neo4j.....10

7. Thống kê mạng đã xây dựng.....11

7.1. Các nút trung tâm.....14

8. Đánh giá sơ bộ chất lượng.....15

9. Kết luận.....16

9.1. Đã đạt được.....16

9.2. Chưa đạt / hạn chế.....16

9.3. Hướng phát triển cho bài cuối kỳ.....17

10. Mã nguồn.....17

1. Phân công công việc trong nhóm

Thành viên	Nhiệm vụ
Nguyễn Nhật Nam (23020557)	Thiết kế lược đồ nút/cạnh và 16 loại quan hệ; xây dựng từ điển thực thể; thu thập dữ liệu báo chí (sitemap, tải và bóc tách bài); xây dựng mô-đun NER và trích xuất quan hệ; lưu trữ đồ thị trên Neo4j và chạy thử thuật toán GDS; quản lý mã nguồn GitHub.
Lưu Đạt Tuấn Nghĩa (23020559)	Tiền xử lý văn bản (chuẩn hóa, tách câu, khử trùng lặp, lọc tin đồn); gộp cạnh và tính độ hỗ trợ; thống kê, trực quan hóa mạng; lấy mẫu kiểm tra chất lượng; viết và hoàn thiện báo cáo.

2. Giới thiệu mạng đã xây dựng

2.1. Bài toán và phạm vi

Đề tài 24 yêu cầu xây dựng mạng lưới kết nối các ngôi sao âm nhạc, thần tượng K-Pop và ca sĩ Âu Mỹ (US-UK) với các tập đoàn giải trí quốc tế (HYBE, SM, YG, JYP, Universal Music…) và các nhãn hàng, dựa trên tin tức báo chí. Đây là loại mạng thông tin – xã hội đa quan hệ (multi-relational, heterogeneous network): các nút thuộc nhiều loại thực thể, các cạnh có hướng, có loại và có trọng số.

Phạm vi được nhóm lựa chọn: toàn bộ K-Pop và nhạc US-UK (không thu hẹp), với mục tiêu tối thiểu 2.000 nút, 5.000 cạnh và 10 loại quan hệ. Dữ liệu là bài báo tiếng Việt (nguồn chính) và tiếng Anh (bổ sung) đăng trong khoảng 07/2023 – 11/2026.

Ý nghĩa kinh doanh: mạng cho phép trả lời các câu hỏi như nhãn hàng nào đang dùng idol nào làm đại sứ, nghệ sĩ nào có sức ảnh hưởng trung tâm (centrality) để lựa chọn cho chiến dịch influencer marketing, các cụm cộng đồng nghệ sĩ – công ty – nhãn hàng, và theo dõi biến động hợp đồng/tranh chấp pháp lý giữa nghệ sĩ và công ty quản lý (ví dụ vụ NewJeans – ADOR – HYBE).

2.2. Lựa chọn nút

Nguyên tắc: mỗi nút là một thực thể có danh tính rõ ràng trong ngành giải trí, và chỉ đưa vào đồ thị khi tham gia ít nhất một quan hệ nghiệp vụ được trích xuất từ báo. Nhóm KHÔNG dùng bài báo, câu văn hay từ khóa làm nút; bài báo và câu dẫn chứng chỉ là metadata gắn trên cạnh.

Loại nút	Ý nghĩa	Ví dụ	Số nút
Artist	Nghệ sĩ / idol / ca sĩ	Jennie, Taylor Swift,	976

	solo / nhà sản xuất	Jungkook	
Group	Nhóm nhạc, ban nhạc	BLACKPINK, BTS, NewJeans, Coldplay	293
Company	Tập đoàn giải trí, công ty quản lý, hãng đĩa	HYBE, ADOR, SM Entertainment, Universal Music Group	85
Brand	Nhãn hàng thời trang, xa xỉ, mỹ phẩm, tiêu dùng	Chanel, Dior, Calvin Klein, Samsung	57
Award	Giải thưởng / lễ trao giải âm nhạc	MAMA Awards, Grammy Awards, Golden Disc Awards	25
Event	Sự kiện, lễ hội, show âm nhạc, tuần lễ thời trang	Coachella, Inkigayo, Met Gala	39
Song	Bài hát / đĩa đơn	APT., Supernova, Espresso	1.793
Album	Album / EP / mini album	Born Pink, Rosie	1.155

Tổng số nút: 4.423, trong đó 2.948 nút tác phẩm (bài hát/album, 67%) và 1.475 nút người/tổ chức/sự kiện. Tác phẩm được giữ làm nút tương tự cách đề bài lấy ví dụ 'quan hệ giữa các diễn viên thông qua các bộ phim': chúng là thực thể có tên riêng, được trích từ báo và nối các nghệ sĩ với nhau. Thuộc tính của nút: id (mã Wikidata QID nếu có, hoặc mã nội bộ), name (tên chuẩn), type, popularity (số liên kết Wikipedia – dùng để khử nhập nhằng), mentions (số lần xuất hiện trong quan hệ).

2.3. Lựa chọn cạnh (loại quan hệ)

Cạnh được thiết kế theo nghiệp vụ của đề tài (Debut/Tái ký hợp đồng, Kiện chấm dứt hợp đồng, Hợp tác toàn cầu, Đại diện thời trang) và được mở rộng để mô tả đầy đủ vòng đời nghệ sĩ. Mỗi loại cạnh có ràng buộc kiểu nút nguồn → nút đích, nên một cạnh chỉ được tạo khi hai thực thể đúng loại cùng xuất hiện trong một câu có từ kích hoạt tương ứng.

Loại quan hệ	**Ý nghĩa**	**Nguồn → Đích**	**Số cạnh**
RENEWED_CONTRACT	Tái ký / gia hạn hợp đồng với công ty	Artist/Group → Company	39
LEFT_COMPANY	Rời công ty / chấm dứt hợp đồng	Artist/Group → Company	114
SIGNED_WITH	Ký hợp đồng / đầu quân	Artist/Group →	102

	cho công ty	Company	
DEBUTED_UNDER	Ra mắt dưới trướng công ty	Artist/Group → Company	145
LEFT_GROUP	Rời nhóm / rút khỏi nhóm / hoạt động solo	Artist → Group	31
MEMBER_OF	Là thành viên của nhóm	Artist → Group	759
LEGAL_ACTION	Kiện tụng / tranh chấp pháp lý	Artist/Group/Company → Artist/Group/Company	87
COLLABORATED_WITH	Hợp tác âm nhạc (collab, featuring, song ca)	Artist/Group ↔ Artist/Group	272
BRAND_AMBASSADOR	Đại sứ / gương mặt đại diện nhãn hàng	Artist/Group → Brand	189
RELEASED	Phát hành bài hát / album	Artist/Group → Song/Album	2.980
WON_AWARD	Giành giải thưởng / chiến thắng chương trình âm nhạc	Artist/Group → Award/Event	446
NOMINATED_FOR	Được đề cử giải thưởng	Artist/Group → Award	75
PERFORMED_AT	Biểu diễn tại sự kiện / lễ hội / lễ trao giải	Artist/Group → Event/Award	481
SUBSIDIARY_OF	Công ty con / nhãn trực thuộc tập đoàn	Company → Company	27
ACQUIRED_STAKE	Thâu tóm / mua cổ phần / đầu tư vào công ty	Company → Company	16
PRODUCED_FOR	Sáng tác / sản xuất cho nghệ sĩ	Artist → Artist/Group/Song/Album	15

Tổng số cạnh (bộ ba duy nhất nguồn – quan hệ – đích): 5.778; số loại quan hệ có cạnh: 16. Thuộc tính cạnh: support (số bài báo khác nhau làm dẫn chứng), first_date/last_date (ngày bài báo sớm/muộn nhất), langs, sources, evidence_sentences và evidence_urls (tối đa 3 câu dẫn chứng kèm URL).

2.4. Ví dụ cạnh kèm dẫn chứng

Cạnh	**Câu dẫn chứng (trích từ báo)**	**Support**
Rosé –[RENEWED_CONTRACT]→ YG Entertainment	Jisoo lộ diện với biểu cảm gây chú ý giữa tin Rosé là thành viên BLACKPINK duy nhất tái ký với YG	18
NewJeans –[LEFT_COMPANY]→	Trước đó vào đêm 29-11-2024,	21

ADOR	NewJeans tổ chức họp báo, đơn phương tuyên bố kết thúc hợp đồng với ADOR của HYBE.	
Jennie –[SIGNED_WITH]→ YG Entertainment	Jennie sinh năm 1996 tại Hàn Quốc, từng đi du học trước khi đầu quân cho YG Entertainment.	22
Illit –[DEBUTED_UNDER]→ Hybe	Sau màn ra mắt của nhóm nhạc nữ mới nhất ILLIT, khán giả bắt đầu có những sự so sánh về các nhóm nhạc nữ nhà HYBE.	15
Seungri –[LEFT_GROUP]→ BigBang	Seungri rời khỏi BIGBANG và bị kết án 1 năm 6 tháng tù giam.	8
Jennie –[MEMBER_OF]→ Blackpink	Jennie (BLACKPINK) được cho là đang hẹn hò với bạn trai mới - nam diễn viên Nico Hiraga .	330
Hybe –[LEGAL_ACTION]→ Min Hee-jin	HYBE tuyên bố sẽ tiến hành thủ tục khởi kiện Min Hee Jin, khẳng định đã có đủ bằng chứng pháp lý.	13
Blackpink –[COLLABORATED_WITH]→ Zico	Doyoung's "Little Light" debuted at No. 2, while Block B's Zico 's new single " SPOT! " (featuring BLACKPINK 's Jennie) entered the chart at No. 3.	18
Jisoo –[BRAND_AMBASSADOR]→ Dior	Một bên là Jisoo - biểu tượng nhan sắc châu Á với nét đẹp dịu dàng, thanh lịch đậm chất "nàng thơ Dior".	26
Jung Kook –[RELEASED]→ Seven	NewJeans ' " Super Shy " held onto its spot at No. 4, with BTS 's Jungkook 's " Seven " (featuring Latto) climbing to No. 5.	85
Lisa –[WON_AWARD]→ MTV Video Music Awards	Đây là lần thứ tư Lisa giành chiến thắng tại VMAs trong sự nghiệp.	15
Taylor Swift –[NOMINATED_FOR]→ Grammy Awards	Beyoncé và Taylor Swift dẫn đầu đề cử Grammy 2025	9
Jennie –[PERFORMED_AT]→ Coachella	Bất chấp tranh cãi, đây chính xác là điểm hoàn hảo nhất sân khấu Coachella 2025 của Jennie.	46
Belift Lab –[SUBSIDIARY_OF]→ Hybe	Sau vụ việc tài liệu mật bị lộ của HYBE, công ty con Belift Lab cũng rơi vào tầm ngắm khi bị lộ tài liệu bổ sung được cho là từ kế hoạch ra mắt của ILLIT.	12
Hybe –[ACQUIRED_STAKE]→ Ithaca Holdings	Tại Mỹ, HYBE đã sớm gia tăng sức ảnh hưởng khi mua lại Ithaca Holdings của Scooter Braun từ năm	3

	2021.	
Teddy Park – [PRODUCED_FOR]→ Blackpink	Là nhóm nữ đầu tiên do chính Teddy - nhà sản xuất "ruột" của YG, từng tạo nên thành công cho BLACKPINK đỡ đầu, MEOVV được đặt trên vai nhiều kỳ vọng to lớn.	3

3. Stack công nghệ thu thập và xử lý dữ liệu

Lưu ý: mẫu báo cáo của đề bài nhắc tới Wikipedia, nhưng đề tài 24 được phân công nguồn BÁO CHÍ. Toàn bộ quan hệ trong đồ thị được trích xuất từ văn bản bài báo. Wikidata chỉ được dùng làm từ điển tên thực thể (gazetteer) phục vụ bước nhận dạng thực thể, không dùng để sinh cạnh.

Thành phần	**Công nghệ**	**Vai trò**
Ngôn ngữ	Python 3.15	Toàn bộ pipeline
Thu thập	requests, sitemap XML, robots.txt	Liệt kê và tải bài báo; độ trễ lịch sự 0,5 s/yêu cầu
Bóc tách HTML	BeautifulSoup4	Lấy tiêu đề, sapo, ngày đăng, các đoạn thân bài
Từ điển thực thể	Wikidata SPARQL + danh sách thủ công	30.239 thực thể ứng viên kèm bí danh
NER	pyahocorasick (Aho–Corasick) + luật biên từ + mẫu regex	Nhận dạng tên nghệ sĩ, nhóm, công ty, nhãn hàng, giải thưởng, sự kiện, bài hát/album
Trích xuất quan hệ	Luật trigger song ngữ Việt–Anh + ràng buộc kiểu	Phân loại 16 loại quan hệ
CSDL đồ thị	Neo4j Community 2026.10 + GDS + APOC	Lưu trữ, truy vấn Cypher, chạy thuật toán đồ thị
Phân tích	NetworkX, Matplotlib	Thống kê mạng, biểu đồ
Báo cáo / mã nguồn	python-docx, Git/GitHub	Sinh báo cáo, quản lý mã

Lý do chọn Neo4j: (1) mô hình property graph phù hợp đồ thị dị thể nhiều loại cạnh; (2) Cypher thuận tiện cho truy vấn đường đi, láng giềng nhiều bước; (3) thư viện Graph Data Science có sẵn PageRank, Louvain, Betweenness, Node Similarity, Link Prediction — đáp ứng các thuật toán cho bài tập cuối kỳ (phát hiện cộng đồng, dự đoán liên kết, tìm người ảnh hưởng).

3.1. Kiến trúc pipeline

Bước 1. build_gazetteer.py — dựng từ điển thực thể từ Wikidata (nhóm K-pop, nghệ sĩ K-pop, nghệ sĩ/ban nhạc US-UK-CA-AU-IE, thành viên nhóm, hãng đĩa, bài hát/album) và danh sách thủ công (nhãn hàng, giải thưởng, sự kiện, công ty Hàn).

Bước 2. collect_urls.py — đọc sitemap theo ngày của 5 trang báo, lọc URL theo slug chứa tên thực thể/từ khóa K-pop – US-UK.

Bước 3. fetch_articles.py — tải bài, bóc tách nội dung.

Bước 4. extract.py — tiền xử lý, tách câu, NER, trích xuất quan hệ, lưu bộ ba kèm dẫn chứng.

Bước 5. build_graph.py — gộp bộ ba, tính support, loại câu tin đồn/phủ nhận, xuất nodes.csv/edges.csv.

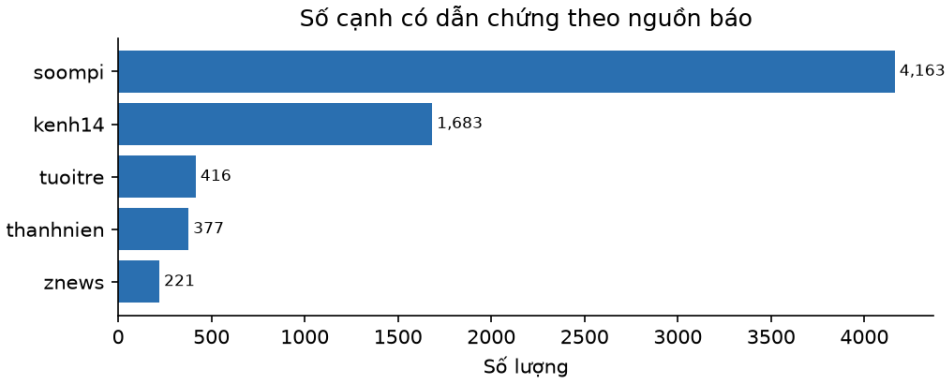
Bước 6. load_neo4j.py — nạp vào Neo4j, chạy PageRank/Louvain/Degree bằng GDS.

Bước 7. stats.py — thống kê mạng và vẽ biểu đồ; report/build_report.py — sinh báo cáo này.

4. Thu thập dữ liệu

Các trang được chọn đều cho phép thu thập với User-agent chung trong robots.txt. Nhóm không thu thập Billboard và VnExpress vì robots.txt của hai trang này hạn chế nhiều loại bot thu thập tự động. Mỗi luồng tải nghỉ 0,5–0,8 giây giữa hai yêu cầu.

Nguồn	Ngôn ngữ	URL sau lọc	Bài tải thành công
Kênh14 (kenh14.vn)	Việt	14.921	14.874
Thanh Niên (thanhnien.vn)	Việt	3.377	3.323
Tuổi Trẻ (tuoitre.vn)	Việt	2.640	2.612
Znews (znews.vn)	Việt	1.687	1.681
Soompi (soompi.com)	Anh	10.718	10.712
Tổng		33.343	33.202



Hình 1. Số cạnh có dẫn chứng theo từng nguồn báo

5. Các bước tiền xử lý dữ liệu

Bước	**Mô tả**
Lọc URL theo slug	Slug URL (không dấu) được tách n-gram 1–4 từ và so với tập slug của tên thực thể trong từ điển + từ khóa (kpop, idol, sao-au-my, dai-su-toan-cau…) để giữ bài đúng chủ đề.
Bóc tách nội dung	Bỏ script/style/figure/caption/bảng/iframe; lấy khối HTML có nhiều đoạn <p> trực tiếp nhất làm thân bài; bỏ đoạn < 25 ký tự và dòng 'Nguồn/Ảnh/Video/Xem thêm'.
Khử trùng lặp	Loại URL trùng và bài đăng lại có cùng tiêu đề + đoạn mở đầu.
Chuẩn hóa văn bản	Chuẩn Unicode NFC (tránh lỗi tiếng Việt tổ hợp), thống nhất ngoặc kép cong → thẳng, bỏ emoji, ký tự điều khiển, khoảng trắng không ngắt, gộp khoảng trắng.
Tách câu	Tách theo dấu . ! ? … khi theo sau là chữ hoa/số/ngoặc; bảo vệ viết tắt (feat., ft., Inc., U.S., D.O., APT.…); giữ câu dài 15–600 ký tự.
Nhận dạng thực thể	Khớp từ điển Aho–Corasick có kiểm tra biên từ, ưu tiên khớp dài nhất, không chồng lấn; chỉ khớp các biến thể viết hoa hợp lệ (BLACKPINK/Blackpink) để tránh nhầm từ thường; loại bí danh quá ngắn hoặc là từ thông dụng; khử nhập nhằng tên trùng bằng ngữ cảnh nhóm trong cùng bài rồi độ phổ biến.
Nhận dạng bài hát/album	Mẫu regex: chuỗi trong ngoặc kép đứng sau từ khóa (ca khúc, bài hát, single, album, MV, EP, song, track…). Tác phẩm mới được định danh bằng tiêu đề + nghệ sĩ thể hiện để tránh gộp nhầm

	các bài trùng tên.
Đồng tham chiếu đơn giản	Câu mở đầu bằng đại từ/danh từ chỉ người (Cô, Anh, Nữ ca sĩ, Nhóm, She, They, The group…) được gán chủ thể là nhân vật chính của bài (nghệ sĩ/nhóm đầu tiên trong tiêu đề), có kiểm tra khớp loại (Nhóm ↔ Group, Cô/Anh ↔ Artist); không áp dụng cho MEMBER_OF, DEBUTED_UNDER, LEFT_GROUP. Cạnh sinh ra theo cách này được gắn cờ coref.
Lọc tin đồn	Câu chứa 'tin đồn, phủ nhận, bác bỏ, rumor, denied…' không được dùng làm dẫn chứng cho các quan hệ hợp đồng, rời nhóm, đại sứ.

Chỉ số tiền xử lý	**Giá trị**
Bài báo sau khử trùng lặp	33.118
– tiếng Việt / tiếng Anh	22.484 / 10.634
Bài trùng nội dung bị loại	84
Số câu sau tách	694.132
Số lượt nhận dạng thực thể (mention)	449.986
Số lượt quan hệ trích xuất (trước gộp)	29.676
Bài báo có ít nhất 1 quan hệ	10.307
Lượt quan hệ bị loại do tin đồn/phủ nhận	59

5.1. Trích xuất quan hệ

Với mỗi câu có ít nhất hai thực thể, hệ thống duyệt 16 luật. Mỗi luật gồm biểu thức trigger song ngữ, tập loại nút nguồn và tập loại nút đích. Chủ thể là thực thể đúng loại gần nhất bên trái trigger, đối tượng là thực thể đúng loại gần nhất bên phải; với câu bị động ('bị … kiện', 'produced by') chiều được đảo. Khoảng cách giữa hai thực thể không quá 160 ký tự. Riêng MEMBER_OF còn có mẫu cấu trúc độ chính xác cao đặc trưng của báo chí: 'Jennie (BLACKPINK)' và "BLACKPINK's Jennie". Quan hệ COLLABORATED_WITH là đối xứng. Các lượt trích xuất giống nhau được gộp, support là số bài báo khác nhau.

6. Lưu trữ trong Neo4j

Mỗi nút có hai nhãn: :Entity và nhãn loại (:Artist, :Group, :Company, :Brand, :Award, :Event, :Song, :Album); ràng buộc duy

nhất trên Entity.id. Mỗi loại quan hệ là một relationship type của Neo4j, có các thuộc tính support, first_date, last_date, langs, sources, evidence_sentences, evidence_urls.

Ví dụ truy vấn Cypher:

```
// Các nhãn hàng có nhiều đại sứ K-pop nhất
MATCH (a)-[r:BRAND_AMBASSADOR]->(b:Brand)
RETURN b.name, count(a) AS so_dai_su ORDER BY so_dai_su DESC LIMIT 10;

// Mạng lưới quanh HYBE trong 2 bước
MATCH p=(c:Company {name:'HYBE'})-[*1..2]-(x) RETURN p LIMIT 200;

// Tranh chấp pháp lý kèm câu dẫn chứng
MATCH (a)-[r:LEGAL_ACTION]->(b) RETURN a.name, b.name, r.support, r.evidence_sentences[0] ORDER BY r.support DESC;
```

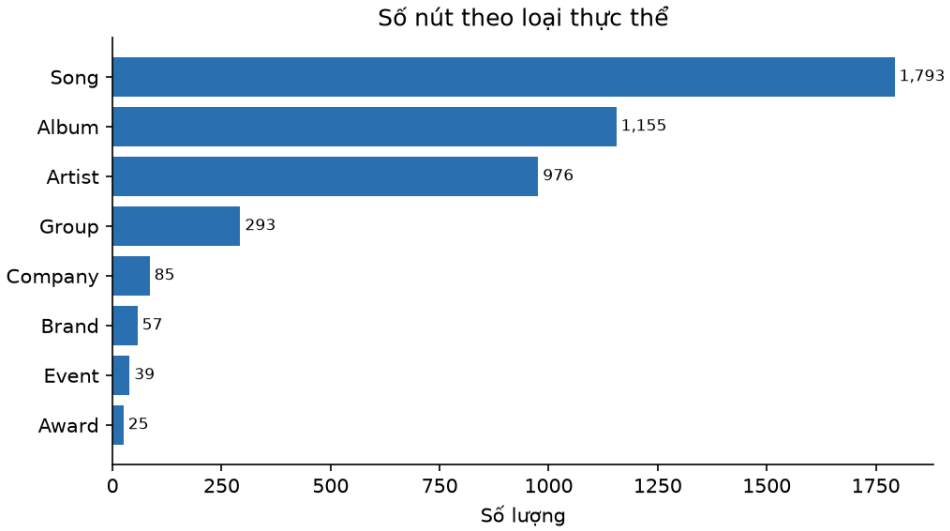
Chạy thử GDS trên Neo4j: Louvain tìm được 220 cộng đồng (modularity 0.789). Top PageRank (có trọng số support):

Thực thể	Loại	PageRank	Bậc
Blackpink	Group	70.488	139
BTS	Group	60.089	137
Seventeen	Group	36.869	93
Aespa	Group	34.155	78
Stray Kids	Group	33.884	102
Lisa	Artist	32.711	66
Jennie	Artist	30.498	90
Le Sserafim	Group	26.346	68
Ive	Group	26.09	62
Enhypen	Group	26.014	67
Twice	Group	25.881	64
Ateez	Group	25.843	57

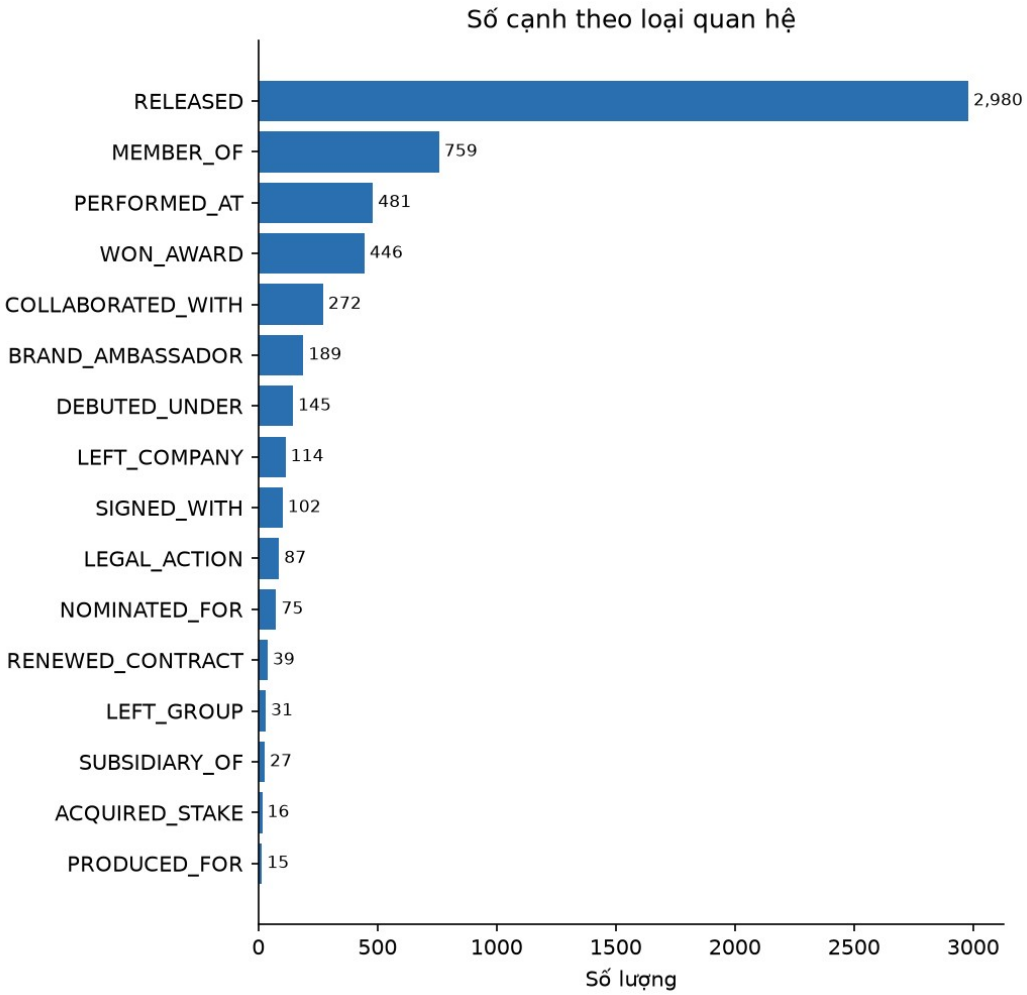
7. Thống kê mạng đã xây dựng

Chỉ số	Giá trị
Số nút	4.423
Số cạnh (có hướng, có loại)	5.778
Số loại quan hệ	16
Số cạnh có support ≥ 2 bài báo	2.323
Số cặp nút kề nhau (đồ thị vô hướng đơn)	5.467
Mật độ (vô hướng)	0.00056

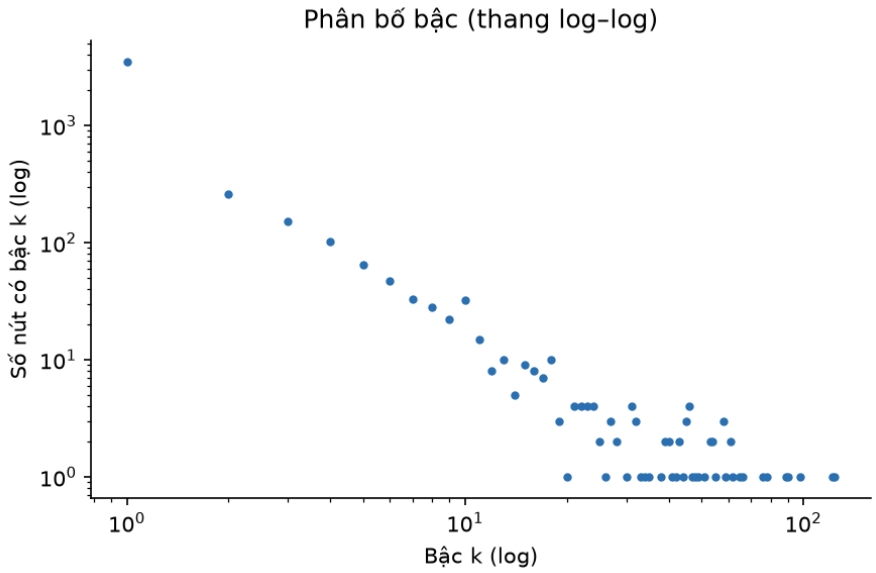
Bậc trung bình / bậc lớn nhất	2.61 / 139
Số thành phần liên thông	180
Thành phần liên thông lớn nhất	3.829 nút (86.6%)
Hệ số phân cụm trung bình	0.0210
Transitivity	0.0256
Độ dài đường đi ngắn nhất TB (TPLT lớn nhất, lấy mẫu 300 nút)	4.97
Số cộng đồng Louvain (NetworkX) / modularity	225 / 0.800



Hình 2. Số nút theo loại thực thể

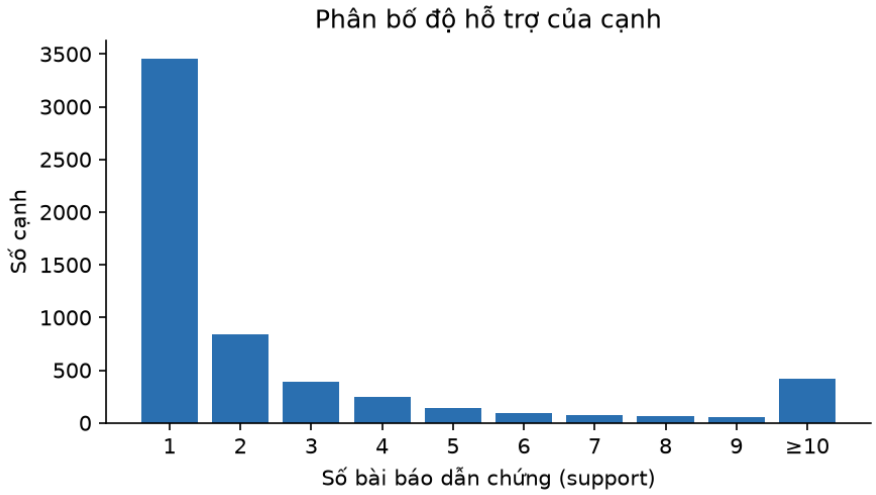


Hình 3. Số cạnh theo loại quan hệ



Hình 4. Phân bố bậc trên thang log–log

Phân bố bậc có đuôi dài: phần lớn nút có bậc nhỏ, một số ít nút (idol/nhóm/công ty lớn) có bậc rất cao, phù hợp với tính chất power-law thường gặp ở mạng xã hội. Đường đi ngắn nhất trung bình nhỏ so với kích thước mạng, thể hiện tính small-world.



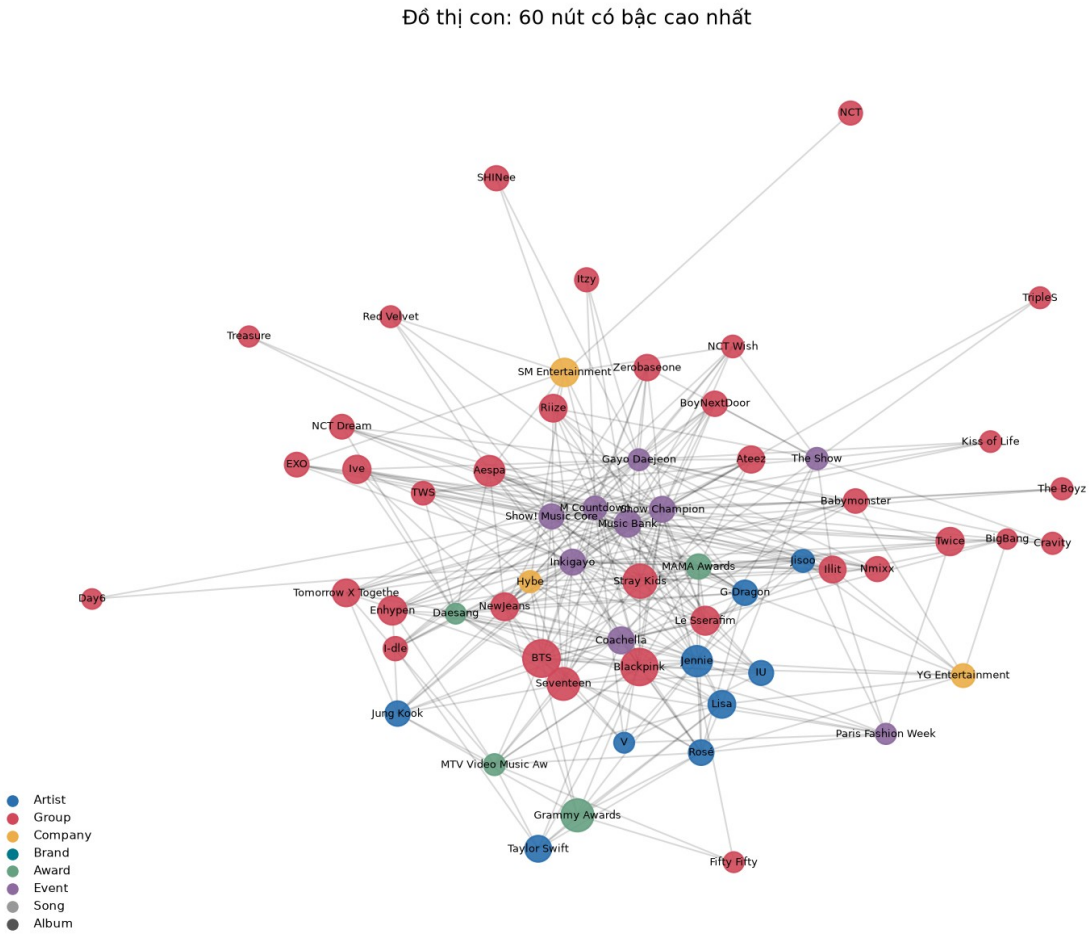
Hình 5. Phân bố số bài báo dẫn chứng của mỗi cạnh

7.1. Các nút trung tâm

Top bậc	Bậc	Top PageRank	PageRank
BTS (Group)	124	Grammy Awards (Award)	0.0071
Blackpink (Group)	122	Hybe (Company)	0.0051
Stray Kids (Group)	98	SM Entertainment (Company)	0.0046
Grammy Awards (Award)	90	YG Entertainment (Company)	0.0024
Seventeen (Group)	89	Coachella (Event)	0.0023
Jennie (Artist)	78	B.I (Artist)	0.0022
Aespa (Group)	76	Waterbomb (Event)	0.002
Enhypen (Group)	66	MAMA Awards (Award)	0.0017
Le Sserafim (Group)	65	Blackpink (Group)	0.0015
SM Entertainment (Company)	62	TripleS (Group)	0.0014
Twice (Group)	61	Riize (Group)	0.0014
Ive (Group)	61	Music Bank (Event)	0.0013

Nhãn hàng (bậc)	Công ty (bậc)	Nhóm nhạc (bậc)	Nghệ sĩ (bậc)
Chanel (15)	SM Entertainment (62)	BTS (124)	Jennie (78)
Dior (10)	YG Entertainment (39)	Blackpink (122)	Lisa (58)
Celine (10)	Hybe (32)	Stray Kids (98)	Taylor Swift (53)
Louis Vuitton (10)	JYP Entertainment (21)	Seventeen (89)	Rosé (47)
Bulgari (10)	The Black Label (18)	Aespa (76)	Jung Kook (46)
Calvin Klein (9)	Cube Entertainment (15)	Enhypen (66)	G-Dragon (46)

Saint Laurent (8)	ADOR (9)	Le Sserafim (65)	IU (44)
Prada (8)	Big Hit Music (9)	Twice (61)	Jisoo (35)
Miu Miu (6)	Mnet (8)	Ive (61)	V (27)
Gucci (6)	Starship Entertainment (7)	NewJeans (59)	Taeyeon (23)



Hình 6. Đồ thị con gồm 60 nút có bậc cao nhất

8. Đánh giá sơ bộ chất lượng

Lấy mẫu ngẫu nhiên phân tầng 160 cạnh (mỗi loại quan hệ tối đa 10 cạnh, file data/graph/review_sample.csv) và đánh giá đúng/sai bằng cách đọc câu dẫn chứng: cạnh đúng khi câu thể hiện đúng loại quan hệ và đúng chiều. Tỷ lệ đúng trên mẫu phân tầng: 76.2%; khi quy đổi theo tỷ trọng số cạnh thực tế của từng loại quan hệ: 84.0%. Trong quá trình xây dựng, việc kiểm tra này được lặp lại ba lượt để sửa luật (59% → 71% → 76% trên mẫu phân tầng). Đây là kiểm tra sơ bộ trên mẫu nhỏ, chưa phải đánh giá chính thức; theo đề bài, chỉ tiêu chất lượng ≥ 90% sẽ được đánh giá ở bài tập cuối kỳ.

Loại quan hệ	**Số mẫu**	**Đúng**	**Tỷ lệ**

ACQUIRED_STAKE	10	6	60%
BRAND_AMBASSADOR	10	7	70%
COLLABORATED_WITH	10	5	50%
DEBUTED_UNDER	10	7	70%
LEFT_COMPANY	10	9	90%
LEFT_GROUP	10	10	100%
LEGAL_ACTION	10	3	30%
MEMBER_OF	10	9	90%
NOMINATED_FOR	10	9	90%
PERFORMED_AT	10	9	90%
PRODUCED_FOR	10	10	100%
RELEASED	10	9	90%
RENEWED_CONTRACT	10	8	80%
SIGNED_WITH	10	7	70%
SUBSIDIARY_OF	10	7	70%
WON_AWARD	10	7	70%

9. Kết luận

9.1. Đã đạt được

- Mạng gồm 4.423 nút (đạt chỉ tiêu 2.000), 5.778 cạnh (đạt chỉ tiêu 5.000) và 16 loại quan hệ (đạt chỉ tiêu 10).
- Toàn bộ cạnh có dẫn chứng là câu văn và URL bài báo, truy vết được nguồn gốc.
- Dữ liệu song ngữ Việt – Anh từ 5 trang báo, pipeline tự động hoàn toàn và chạy lại được.
- Đồ thị lưu trên Neo4j, đã chạy thử thuật toán PageRank, Louvain, Degree bằng GDS.

9.2. Chưa đạt / hạn chế

- Độ chính xác ước lượng hiện ở mức khoảng 76–84% (mẫu 160 cạnh), chưa đạt mức ≥ 90%; các quan hệ yếu nhất là LEGAL_ACTION, COLLABORATED_WITH và ACQUIRED_STAKE. Chưa đo recall.

- Nút tác phẩm (bài hát/album) chiếm tỷ trọng lớn; nếu chỉ tính nút người/tổ chức thì số nút thấp hơn 2.000.
- Trích xuất quan hệ bằng luật nên bỏ sót các câu diễn đạt gián tiếp và có thể gán sai chiều ở câu phức nhiều thực thể.
- NER phụ thuộc từ điển: nghệ sĩ mới/ít nổi tiếng chưa có trong Wikidata sẽ không được nhận dạng; tên ngắn dễ nhập nhằng (V, Jin, Joy…).
- Đồng tham chiếu mới ở mức luật đơn giản (đại từ đầu câu → nhân vật trong tiêu đề); các trường hợp phức tạp hơn (nhóm, nam ca sĩ ở giữa câu, nhiều nhân vật) chưa được khai thác.
- Quan hệ có tính thời điểm (ký/rời hợp đồng) mới chỉ lưu ngày bài báo, chưa chuẩn hóa thời gian hiệu lực.

9.3. Hướng phát triển cho bài cuối kỳ

- Gán nhãn tay 500–1.000 câu để đo độ chính xác và huấn luyện mô hình phân loại quan hệ (PhoBERT/XLM-R).
- Dùng LLM miễn phí (ví dụ Gemini free tier) để kiểm chứng lại các cạnh support = 1.
- Bổ sung đồng tham chiếu và chuẩn hóa thực thể mới (entity linking).
- Phân tích cộng đồng, dự đoán liên kết (idol – nhãn hàng), xếp hạng người ảnh hưởng.

10. Mã nguồn

Link GitHub: https://github.com/Erige005/INT3035-Nhom22

Kho mã gồm toàn bộ script pipeline (src/), danh sách thực thể thủ công (config/), từ điển thực thể, danh sách URL, bộ ba quan hệ kèm dẫn chứng, nodes.csv/edges.csv, thống kê và mã sinh báo cáo. Nội dung đầy đủ của bài báo không được đưa lên kho để tôn trọng bản quyền của các tòa soạn.